

清 华 大 学

综 合 论 文 训 练

题目：基于 GPU 的极化 SAR 图像舰
船检测算法设计

系 别：电子工程系

专 业：电子信息科学与技术

姓 名：孙天宇

指导教师：杨健 教授

2020 年 5 月 15 日

关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：学校有权保留学位论文的复印件，允许该论文被查阅和借阅；学校可以公布该论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存该论文。

(涉密的学位论文在解密后应遵守此规定)

签 名：_____ 导师签名：_____ 日 期：_____

中文摘要

合成孔径雷达 (SAR) 作为一种主动成像的遥感观测手段, 可以通过收发电磁波波束来获取地物目标的极化散射信息, 生成高分辨率的地物影像。目前 SAR 被广泛应用于海上目标检测与识别。为满足 SAR 系统对海上目标检测的高时效性要求, 本文共实现了三种基于 CPU+GPU 异构架构的高效并行舰船目标检测方法, 总结如下:

1) 对于极化 SAR 图像, 以极化白化滤波器 (PWF) 方法为例, 实现了多 GPU 协同的并行极化白化滤波器舰船检测算法。该方法使用滑动窗选取局部海杂波像素来计算自适应极化白化滤波器参数, 通过该滤波器融合各个极化通道的散射信息, 得到一幅相干斑抑制图像。对重构降斑图像应用 CFAR 检测器进行阈值分割, 得到最终的检测结果。实验结果表明, 基于 GPU 的并行 PWF 舰船检测算法有效, 并在检测时间性能上获得了显著的提升, 明显优于传统的 CPU 串行算法。

2) 对于单极化 SAR 图像, 采用了混合对数正态分布来描述强度图像中的非负海杂波分布。首先采用滑动窗选择局部海杂波像素, 然后采用最大期望 (EM) 方法来估计混合对数正态分布中参数, 得到分布后根据给定的虚警率采用牛顿迭代法计算 CFAR 检测器的分割阈值。我们将该算法中参数估计与阈值计算等可并行执行的部分分配到 GPU 上去并行执行。实验结果表明, 相比于传统 CPU 串行执行方式, 该并行方法在时间性能上获得了数十倍的提升。

3) 实现了基于 GPU 的极化协方差差异矩阵极化 SAR 图像舰船检测方法。该方法计算了图像中每个像元与其 3×3 邻域极化协方差矩阵的差值, 由此得到极化协方差差异矩阵。为了充分利用极化协方差差异矩阵中含有的极化信息, 在每个 GPU 线程中, 我们提取了极化协方差差异矩阵的 SPAN 值与基座舰船高度 (PSH) 这个极化特征, 对这两个特征应用阈值分割, 得到最终检测结果。实验结果表明: 相较于 PWF 方法, 该方法对复杂海况的适应能力更强, 算法在检测精度与时间、空间性能上都优于 PWF 方法。

关键词: 舰船检测; 高性能计算; 极化白化滤波器; 极化协方差差异矩阵; 极化 SAR

ABSTRACT

Synthetic aperture radar (SAR) system provides an all-weather remote sensing method. It can generate high resolution ground-object images via radar beam irradiation. The SAR data has been widely used in ship detection and classification as well as other fields. In order to meet the real-time processing requirement of SAR system, this thesis suggests a method based on a CPU+GPU heterogeneous architecture for SAR image processing. Then three kinds of effective target detectors are realized by a CPU+GPU heterogeneous architecture. The main contributions of this thesis are summarized as follows:

1) For polarimetric SAR image, this thesis implements a parallel polarimetric whitening filter method for ship detection based on GPU processors. This method uses local sea clutter to calculate the filter parameters. After that we use this whitening filter to combine the elements of the scattering matrix and get a coherent speckle suppression image. For this reconstruct image, a CFAR detector is applied to get the detection results. The experiment result shows that this method is effective and the detection time is significantly decreased compared with the traditional CPU platform.

2) For SAR image, the lognormal mixture model is used to describe the non-negative sea clutter distribution. In this method, the maximum expectation (EM) algorithm is used to effectively estimate the sea clutter distribution. According to the given false alarm rate, the detection threshold is obtained by Newton iteration method. The experiment result of this method on the NVIDIA TITAN V GPU platform shows that compared with the traditional CPU platform, the detection time performance of this method is improved by dozens of times.

3) A ship detection method based on polarimetric covariance difference matrix is implemented. This method calculates the polarimetric covariance matrix difference between each pixel and its neighborhood. The polarimetric covariance difference matrix improves the ship-sea contrast ratio in the local area. In order to make full use of the polarization and intensity features in the polarimetric covariance difference matrix, the SPAN value and the PSH feature of the polarimetric covariance difference matrix is

calculated. Finally the experiential threshold is used to obtain the detection result. The experiment results show that, compared with the PWF method, the detection accuracy and efficiency of this method has been effectively improved.

Keywords: ship detection; CUDA; polarimetric whitening filter; polarimetric covariance difference matrix; polarimetric synthetic aperture radar

目 录

第 1 章 引言	1
1.1 研究背景与意义	1
1.2 研究现状与进展	2
1.2.1 单极化 SAR 舰船目标检测	2
1.2.2 极化 SAR 舰船目标检测	3
1.3 论文内容	4
第 2 章 基于 PWF 的极化 SAR 图像舰船目标检测	6
2.1 引言	6
2.2 海杂波统计特性	6
2.3 极化白化滤波器	7
2.4 自适应 PWF 舰船检测算法	8
2.5 基于 GPU 的 PWF 算法实现	9
2.5.1 GPU 算法设计与优化	9
2.5.2 多 GPU 协同算法设计	11
2.6 实验结果与加速比测试	11
2.7 小结	12
第 3 章 基于混合对数正态模型 SAR 图像目标检测	14
3.1 引言	14
3.2 混合对数正态模型	14
3.3 海杂波分布参数估计	15
3.4 应用 LMM 模型进行 CFAR 舰船检测	16
3.5 GPU 算法优化	17
3.6 LMM 实验结果	19
3.7 小结	20
第 4 章 基于 PCDM 的极化 SAR 图像舰船目标检测	22
4.1 引言	22
4.2 PCDM 理论背景	22

4.2.1 极化 SAR 散射表征与 SPAN 理论	22
4.2.2 极化协方差差异矩阵	23
4.3 基于 PCDM 的舰船目标检测算法	24
4.4 基于 GPU 的 PCDM 算法设计	26
4.5 PCDM 算法检测结果	27
4.6 小结	30
第 5 章 总结与展望	32
插图索引	33
表格索引	34
公式索引	35
致 谢	37
声 明	38
附录 A 外文资料的调研阅读报告或书面翻译	39
A.1 介绍	39
A.2 极化 SAR 图像概率模型	41
A.2.1 极化 SAR 图像的表示	41
A.2.2 稀疏分量 \mathbf{A} 的先验分布	42
A.2.3 海杂波 \mathbf{C} 的先验分布	42
A.3 变分贝叶斯推断	44
A.3.1 变分贝叶斯推断原理	44
A.3.2 变分贝叶斯推断在舰船检测中的应用	45
A.3.3 算法	46
A.4 实验与结果	47
A.4.1 参数设置	48
A.4.2 定义真值	49
A.5 结论	49

主要符号对照表

HPC	高性能计算 (High Performance Computing)
CUDA	统一计算设备架构 (Compute Unified Device Architecture)
GPU	图形处理器 (Graphics Processing Unit)
SAR	合成孔径雷达 (Synthetic Aperture Radar)
CFAR	恒虚警率 (Constant False Alarm Rate)
SPAN	散射总功率
CTD	相干目标分解 (Coherent Target Decomposition)
ICTD	非相干目标分解 (Incoherent Target Decomposition)
PWF	极化白化滤波器 (Polarimetric Whitening Filter)
APWF	自适应极化白化滤波器
LMM	混合对数正态模型 (Lognormal Mixture Model)
EM	最大期望算法 (Expectation Maximization algorithm)
PCDM	极化协方差差异矩阵
LBP	局部二值模式 (Local Binary Patterns)
PSH	基座舰船高度 (Pedestal Ship Height)
\mathbf{X}^T	矩阵转置
\mathbf{X}^H	矩阵共轭转置
Γ	Gamma 函数
$E(\cdot)$	计算期望
$ $	矩阵行列式或绝对值
\ln	对数函数
\exp	指数函数
Σ_c	极化协方差矩阵
p_{fa}	虚警概率
F_1	品质因数
T	检测阈值

第 1 章 引言

1.1 研究背景与意义

合成孔径雷达 (synthetic aperture radar,SAR)^[1] 以微波遥感的形式进行对地观测, 可以不受天气、光照等自然条件的影响, 具有全天候、全天时的实时对地观测能力。鉴于 SAR 系统可以提供丰富的地物散射特征等信息, 目前其被广泛应用于自然灾害评估, 海洋维权, 对地侦察, 资源勘探等领域^[2]。SAR 技术自从 20 世纪 50 年代诞生以来, 已经取得了长足的发展。最初其被应用于侦察和检测人造目标等军用领域, 进入到七十年代, 一些用来探测地表物理特征的民用机载 SAR 系统被相继研发。1978 年, 第一颗民用 SAR 卫星 Seasat 发射。二十世纪九十年代欧洲、日本、加拿大分别发射了 ERS-1/2、JERS-1、Radarsat-1 星载 SAR 系统。21 世纪进入 SAR 系统发展的黄金时代, 如今在轨运行的星载 SAR 系统超过 20 个, 我国于 2016 年发射了高分三号遥感卫星 (GF-3), 这是一颗 C 波段分辨率达到 1 米的多极化合成孔径雷达卫星。

广泛的应用场景需求在不断推动着 SAR 成像技术的迅猛发展, 起初 SAR 系统只能以一种收发电磁波的模式去获取数据, 工作频段、角度单一。如今 SAR 系统成像模式日渐多样化, 产生了多极化, 多角度, 多波段, 多识相的组合观测模式。相较于单极化 SAR 系统, 多极化 SAR 可以采用多种组合观测模式去获得地物目标的完备的散射信息。目前 SAR 成像技术在向高空间, 时间分辨率的方向发展, 对于高分辨 SAR 影像的后处理以满足各领域应用需求等前沿科学问题正在引发学者广泛关注^[3]。

近几年, 图形处理器 (GPU) 因其高效的计算性能引起了科研人员的广泛关注。最初图形处理器作为协处理器仅被用来加速图像处理与实时图像渲染以提供平滑与流畅的屏幕图形显示。如今随着深度学习的快速发展, GPU 因其强大的数据处理能力与高内存带宽已经成为训练神经网络的标配。在 SAR 领域, GPU 也被广泛应用 SAR 图像的生成与后处理^[4]。与此同时, GPU 编程接口 CUDA 也一直与时俱进, 其提供了一套基于 C/C++ 的 API 以便捷开发人员创建可以在其上运行的软件。

海上舰船目标检测与识别是极化 SAR 重要应用之一。我国海域辽阔, 近些年来海上安全形势日趋严峻, 海洋管控能力亟待提升。基于极化 SAR 的舰船目

标检测与识别对于航线管理，海上救援，航洋权益争端等具有非常重要的意义。然而传统的极化 SAR 目标识别方法存在着计算复杂度高，耗时长等问题。针对此问题，我们基于 CPU+GPU 的异构架构将 SAR 目标检测算法中可并行的部分附加到高速的 GPU 中去执行，从而全面提升 SAR 系统对目标快速检测与处理的能力。




图 1.1 CPU 和 GPU 浮点运算比较

1.2 研究现状与进展

本节介绍 SAR 图像舰船检测方法研究与进展，包含了单极化 SAR 图像舰船检测与极化 SAR 图像舰船目标检测。

1.2.1 单极化 SAR 舰船目标检测

通常星载 SAR 系统可以对大范围海面进行成像，对于原始单通道 SAR 图像数据，舰船目标检测主要包含了以下几个过程：海陆分割，截取含有潜在目标的候选检测区域，使用目标检测算法鉴别候选区域中的舰船像素与杂波像素^[2]。目前大多数检测算法都是依据舰船目标与海面后向散射特性的差异来进行鉴别。舰船目标包含大量二面角，后向散射系数较高，在强度图像中表现为一块高亮区域，而海杂波则为无规则的灰暗斑点噪声形态。

在基于幅值的单极化 SAR 图像舰船目标检测方法中，基于恒虚警率 (CFAR) 的舰船检测方法应用最为广泛。CFAR 检测方法根据滑动窗选择待检测像素周围的海杂波像素，然后按照事先提出的统计分布模型依据选取的海杂波像素去估计杂波分布参数，得到杂波分布后根据恒虚警率 P_{FA} 去计算自适应分割阈值 T ，当待检测像素值大于阈值 T 时将该像素判定为舰船像素^[2]。对于恒虚警率

舰船检测方法,其检测精度主要受到两个因素的影响,雷达系统本身的参数,如极化模式、入射角等,另一个是成像区域海况条件如风速、风向等。

对于海杂波的统计建模方法,Novak^[2]提出了双参数 CFAR 检测方法,该方法采用高斯分布对海杂波进行统计建模,实验结果表明在低分辨率匀质杂波条件下,双参数 CFAR 检测器拥有较好的检测性能。此外研究人员还采用了其他分布模型如瑞利分布、K 分布、对数正态分布、Weibull 分布来描述海杂波分布特性,经实验验证,这些统计模型都可以有效区分 SAR 图像中的舰船目标与背景杂波^[2]。虽然有很多可供选择的统计分布模型,但是在高分辨率的复杂海洋场景中,这些模型对杂波的拟合精度仍然不能满足检测要求,于是一些学者提出了非参数化的检测方法。Jiang et al.^[2]提出了概率神经网络 (Probability neural networks, PNN) 来估计海杂波的概率密度函数。Gao^[2]提出了基于 Parzen-window-kernel 的检测方法,该方法利用 Parzen 窗中的核函数去逼近真实 SAR 图像直方图,从而完成对杂波概率密度函数的估计。近些年来一些基于深度学习的方法也被应用到 SAR 图像目标检测中。Kang^[2]将光学图像目标检测网络 Faster-RNN 与 CFAR 检测器相结合,将 Faster-RCNN 网络输出的举荐目标区域作为滑动窗的保护区域对 CFAR 算法进行改进。实验结果表明,该算法对可以有效提升对 SAR 图像中尺寸较小的舰船目标的检测能力。

1.2.2 极化 SAR 舰船目标检测

极化 SAR 系统通过组合不同的电磁波收发模式获得了更加丰富的地物目标极化散射信息,研究表明加入极化信息可以提升检测器对 SAR 图像中舰船目标的检测能力^[2, 3]。极化 SAR 舰船目标检测方法主要包含两大类,基于海杂波统计分布特性与基于极化分解的方法。在第一类方法中,首先对各个通道极化信息进行融合构造一种新的检测量,其次计算海杂波对应检测量服从的统计分布,最后使用 CFAR 检测器计算检测阈值,当被检测像素大于检测阈值时判定为舰船目标像素。在多通道极化信息融合的方法中,最简单的为 SPAN 即散射矢量极化协方差矩阵的迹,该检测量表征了地物目标的后向散射总功率。极化白化滤波器 (PWF) 以最小化重构图像相干斑噪声的方式去融合不同通道的极化信息,Novak^[2]采用 K 分布对 PWF 重构图像中的海杂波像素进行统计建模,实验结果表明 PWF 方法可以有效抑制图像中的相干斑噪声并得到了不错的检测结果。最优极化检测器 (OPD)^[2]在融合过程中将目标物体的极化协方差矩阵考虑在内,检测性能优于 PWF 方法。对于纹理多变、复杂海况的应用场景,匀质模型不能

很好的对海杂波进行拟合，学者提出了乘积模型，将图像描述为纹理模型与匀质模型的乘积，对纹理模型的统计建模比较常用的有方根 Gamma 分布^[2]，逆 Gamma 分布^[2]，Fisher 分布^[2]等。宋^[2]基于乘积模型提出了基于变分贝叶斯推断的舰船检测方法。

基于极化分解的方法从散射矩阵或相干矩阵中提取目标物体的散射特征。其中散射矩阵的极化分解要求目标回波相干，又被称为相干目标分解 (CTD)。相干分解中最基本的分解为 Pauli 分解，其将散射矩阵分解为表面散射，二面角散射，体散射等泡利基，各散射成分值可表示为一向量，使用支持向量机 (SVM) 的方法对该向量进行分类。另一类是基于协方差矩阵或相干矩阵的非相干目标分解 (ICTD)。1998 年 Freeman^[2]提出了一种基于极化协方差矩阵的分解方法，其将协方差阵分解为体散射，面角散射和二面角散射分量。张涛^[2]提出了基于极化协方差差异矩阵检测方法，该方法利用了检测像素的邻域信息得到了极化协方差差异矩阵，并提取了极化协方差差异矩阵的基础舰船高度 (PSH) 特征用于舰船目标的检测。近些年来一些使用深度卷积神经网络的方法也应用于极化 SAR 图像的检测与分类中^[2]。

1.3 论文内容

本文主要研究了基于 GPU 的极化 SAR 图像舰船检测方法，文章结构框架如图1.2所示，第一章为引言，介绍了极化 SAR 图像舰船目标检测的背景、研究现状和意义。第二章针对极化 SAR 图像，研究了并行的极化白化滤波器舰船检测方法。第三章研究了基于混合对数正态分布的单极化 SAR 图像舰船检测方法。第四章从空间相干矩阵的角度研究了基于协方差差异矩阵的极化 SAR 舰船目标检测方法。



图 1.2 论文内容安排

第二章研究基于 PWF 极化 SAR 舰船检测方法。本章首先介绍了 SAR 图像中斑点噪声的概念。为了抑制斑点噪声，我们将不同通道的极化信息进行融合。并推导出当海杂波散射矢量满足复高斯分布时的极化白化滤波器参数计算公式。之后采用极化白化滤波器生成重构图像，并应用 CFAR 检测器进行检测。本章在完成算法流程分析后，设计了基于 GPU 的并行极化白化滤波器舰船检测算法与多 GPU 协同实现的方案。最后通过实验，我们验证了基于 GPU 算法的有效性与高校性。

第三章研究了基于混合对数正态模型的单极化 SAR 舰船检测方法。本章我们首先介绍了混合对数正态分布的概念与其参数估计方法。然后使用 LMM 模型对海杂波进行建模并应用 CFAR 检测器进行检测。针对该算法中迭代计算分布参数的过程，本章提出了基于 GPU 的优化方案，最后实验结果证明本章的基于 GPU 的方法在算法时间性能上获得了数十倍的提升。

第四章研究了基于极化协方差差异矩阵的极化 SAR 舰船检测方法。本章我们首先回顾了极化 SAR 散射表征与 SPAN 理论，并对极化协方差差异矩阵做了详细的介绍。我们提取了极化协方差差异矩阵的 SPAN 值与 PSH 特征用于舰船目标检测并阐述了该算法在 GPU 上实现的具体细节。最后通过实验证明了本章基于 GPU 的 PCDM 舰船检测方法相较于 PWF 方法在时间性能与检测精度上都有明显的提升。

第五章对本文实现的三种并行检测算法进行了总结，并提出了现有工作的不足与对未来工作的展望。

第 2 章 基于 PWF 的极化 SAR 图像舰船目标检测

2.1 引言

在 SAR 图像中，斑点噪声是影响图像品质的主要因素之一。通常其由一个分辨单元内多个散射体的回波相干叠加形成。相干斑的存在导致舰船目标检测中的虚警、漏报率提升，从而影响舰船目标检测的性能，因此相干斑噪声的处理一直被认为是 SAR 图像处理中最重要的问题。在拥有多极化的 SAR 数据后，通过将散射矩阵各个通道信息进行融合，提取极化特征，可以获取相干斑抑制的重构图像。通常图像 SPAN 即散射总功率为最基本的极化特征，相较于单通道 SAR 图像，其可以显著的减少 SAR 图像中的相干斑噪声。在本章中采用了重构图像的标准差 s 与均值 m 比进行相干斑噪声的衡量，并证明了极化白化滤波器可以使该比值达到最小，从而得到最优的重构图像。最后我们采用 PWF 方法与恒虚警率检测器对极化 SAR 图像进行处理，结果表明基于极化白化滤波器的 CFAR 方法可以有效鉴别海上舰船目标。

2.2 海杂波统计特性

此章采用复高斯模型来描述海杂波的数学统计特性，包含三个通道的极化散射矢量描述如下

$$\mathbf{X} = \begin{bmatrix} S_{hh} \\ S_{hv} \\ S_{vv} \end{bmatrix} \quad (2-1)$$

极化散射矢量中的 HH, HV, VV 通道满足联合复高斯分布，因此极化散射矢量满足如下的概率密度分布

$$f(\mathbf{X}) = \frac{1}{\pi^3 |\Sigma_c|} \exp(-\mathbf{X}^H \Sigma_c^{-1} \mathbf{X}) \quad (2-2)$$

其中 $\Sigma_c = E(\mathbf{X}\mathbf{X}^H)$ 是极化散射矢量的协方差矩阵， H 代表共轭转置， $E(\cdot)$ 代表求期望。通常假设海杂波散射矢量的均值为零即 $E(\mathbf{X}) = 0$ ，当同极化矢量 S_{hh} 与交叉极化矢量 S_{hv} 间存在耦合时，海杂波散射矢量的极化协方差矩阵可以描

述为以下的形式：

$$\Sigma_c = \sigma_{hh} \begin{bmatrix} 1 & 0 & \rho\sqrt{\gamma} \\ 0 & \varepsilon & 0 \\ \rho^*\sqrt{\gamma} & 0 & \gamma \end{bmatrix} \quad (2-3)$$

在上式中 * 代表共轭转置，符号变量的定义如2-4所示。

$$\begin{aligned} \sigma_{hh} &= E(|S_{hh}|^2) \\ \varepsilon &= \frac{E(|S_{hv}|^2)}{E(|S_{hh}|^2)} \\ \gamma &= \frac{E(|S_{vv}|^2)}{E(|S_{hh}|^2)} \\ \rho &= \frac{E(S_{hh} \cdot S_{vv})}{\sqrt{E(|S_{hh}|^2)E(|S_{vv}|^2)}} \end{aligned} \quad (2-4)$$

2.3 极化白化滤波器

利用 HH, HV, VV 三个通道的极化信息构建最优图像，采用重构图像的标准差 s 与均值 m 之比进行斑点噪声的度量。下面将证明极化白化滤波器可以使得重构图像的标准差与均值的比值达到最小。

$$\frac{s}{m} = \frac{\sigma(y)}{E(y)} \quad (2-5)$$

式2-5中随机变量 y 代表重构图像的像素值，当给定 SAR 图像 HH、HV、VV 通道极化信息后，通过式2-6来重建斑点抑制图像

$$y = \mathbf{X}^H \mathbf{A} \mathbf{X} \quad (2-6)$$

在式2-6中，权重矩阵 \mathbf{A} 厄米共轭且正定，为了计算得到最优权重矩阵 \mathbf{A}^* ，将式2-5做式2-7所示变换。式2-7中， $\lambda_1, \lambda_2, \lambda_3$ 为矩阵 $\Sigma_c \mathbf{A}$ 的特征值，因此寻找最优权重矩阵的问题被转化为寻找特征值 $\lambda_1, \lambda_2, \lambda_3$ 使得 s/m 比值达到最小。显然当矩阵 $\Sigma_c \mathbf{A}$ 为单位阵、特征值 $\lambda_1 = \lambda_2 = \lambda_3$ 时，该比值达到最小。因此 $\mathbf{A}^* = \Sigma_c^{-1}$ 被称作极化白化滤波器。

$$\begin{aligned}
\sigma(y) &= \text{tr}(\Sigma_c A)^2 = \sqrt{\sum_{i=1}^3 \lambda_i^2} \\
E(y) &= \text{tr}(\Sigma_c A) = \sum_{i=1}^3 \lambda_i \\
\frac{s}{m} &= \frac{\sqrt{\sum_{i=1}^3 \lambda_i^2}}{\sum_{i=1}^3 \lambda_i}
\end{aligned} \tag{2-7}$$

获得极化白化滤波器后，通过式2-8计算相干斑抑制的重构图像。从式2-8可以看出相干斑抑制图像是对 $|S_{hh}|^2, |S_{hv}|^2, |S_{vv}|^2$ 三个通道进行优化权重求和得到的强度图像。相较于单极化强度图像，极化白化滤波器提供了 $4.8dB$ 的相干斑噪声抑制。

$$y = \frac{|S_{hh}|^2}{\sigma_{hh}(1 - |\rho|^2)} + \frac{|S_{vv}|^2}{\sigma_{hh}(1 - |\rho|^2)\gamma} + \frac{|S_{hv}|^2}{\sigma_{hh}\epsilon} - \frac{2\text{Re}(\rho \cdot S_{hh}^* \cdot S_{vv})}{\sigma_{hh}(1 - |\rho|^2)\sqrt{\gamma}} \tag{2-8}$$

采用实验数据来验证 PWF 相干斑抑制效果，实验数据选择的是 C 波段多极化大连港的原始 SAR 图像数据，所截取的图像为 1000x1000 的海洋场景，在自适应极化白化滤波器方法中，使用大小为 31x31 的滑动窗选择海杂波像素来计算极化白化滤波器参数，下表为原图像 HH 通道、SPAN 方法与 APWF (自适应极化白化滤波器) 方法处理后图像的标准差与均值比。

表 2.1 HH、SPAN 与 APWF 强度图像标准差与均值比

滤波方法	HH 强度图像	SPAN 强度图像	APWF 强度图像
s/m	2.02	2.25	11.24

从不同强度图像结果中可以看到，SPAN 强度图像与 APWF 强度图像对相干斑都有抑制效果，并且增强了船-海之间的对比度，可以对重构强度图像进行统计分析来进一步实施舰船检测^[2]。

2.4 自适应 PWF 舰船检测算法

不同天气条件下的海况不同，因此在 SAR 图像不同区域的杂波表现差别也很大，为了让算法具有更好的普适性，采用自适应极化白化滤波器 (Adaptive

PWF) 舰船检测方法。本章前三节描述了当海杂波散射矢量满足复高斯分布时, 可以采用滑动窗选择局部海杂波散射矢量计算极化白化滤波器参数, 并使用该滤波器生成相干斑抑制图像, 在文献^[2]中表明, 使用自适应极化白化滤波器生成的重构强度图像值满足如下分布:

$$f_y(y) = (N)^{N-\rho+1} \frac{y^{(\rho-1)}}{(y+N)^{N+1}} \frac{\Gamma(N+1)}{\Gamma(\rho)\Gamma(N-\rho+1)} \quad (2-9)$$

式2-9中, ρ 为极化散射矢量的维度, N 为滑动窗内极化散射矢量的个数。当给定恒虚警率时依据式2-9我们可以计算检测阈值, 当 N 很大时检测阈值与恒虚警率近似有式2-10所示的关系。式2-10中, T 代表检测阈值, P_{FA} 为恒虚警率。

$$P_{FA} = \exp(-T) \sum_{k=0}^{\rho-1} \frac{T^k}{k!} \quad (2-10)$$

整个算法流程如 Algorithm 1所示, 在该算法中要对图像中的所有像素值进行判断, 因此使用的滑动窗的个数等于图像的像素数量。对于大小为 $N \times N$ 的滑动窗, 计算滑动窗对应的滤波器参数的算法时间复杂度为 $O(N^2)$, 整个算法的时间复杂度为 $O(mnN^2)$, m 、 n 为 SAR 图像的宽度与高度, 因此基于 APWF 检测算法的运行时间与滑动窗和原始 SAR 图像大小有关。当图像或滑动窗尺寸较大时, 算法的时效性差不能满足实时检测的要求, 所以要在时间方面进行优化。在 AWPf 算法中, 各个滑动窗所对应的自适应极化白化滤波器参数估计相互独立, 因此可以采用并行计算的方式来提高算法的运行效率。

2.5 基于 GPU 的 PWF 算法实现

2.5.1 GPU 算法设计与优化

对于 APWF 舰船检测方法, 不同像素对应的自适应极化白化滤波器参数计算过程完全相同, 只是通过滑动窗选取的海杂波数据不同, 因此我们将可并行且计算密集的滤波器参数计算部分放到 GPU 上去执行如算法2所示。在 GPU 编程模型中, 线程有两个并行的层次分别是网格层次和线程块层次, 一个线程块中的线程会作为一个整体被调度到流多处理器上去执行。为充分利用 GPU 硬件资源, 将线程块大小设计为 32×32 即每个线程块中包含 1024 个线程, 网格大小设计为 16×16 。实验中使用的图像大小为 1000×1000 , 故让一个线程块中共 1024

Algorithm 1: 自适应极化白化滤波器舰船检测算法

Input: 极化 SAR 数据, S_{hh} , S_{hv} , S_{vv}

- 1 对原始图像边缘根据所选择的滑动窗大小做镜像延拓。
- 2 **foreach** 图像中的像素 **do**
- 3 从原始 SAR 图像中根据滑动窗选择海杂波散射矢量 \mathbf{X}
- 4 计算自适应极化白化滤波器参数
- 5 根据自适应极化白化滤波器生成重构强度图像值 y
- 6 依据式2-10, 采用牛顿迭代法得到检测阈值 T
- 7 得到检测结果 $result = y > T$
- 8 **end**

Output: 二值舰船检测结果图像 $result$

个线程对应处理 SAR 图像一行的数据, 每个线程通过自身的二维索引和 SAR 图像中的像素一一对应。

将线程索引与像素索引对应后, 从 GPU 全局内存 (Global Memory) 中读取该像素对应滑动窗所选的海杂波数据。在一个线程块内, 数据的读取是以线程束的方式进行的。一个线程束中包含 32 个线程, 当线程束中线程访问的数据地址在 128 字节范围内时, 该访问可以进行合并。合并访问可以大大加快内存访问的速度, 提升总线利用效率。因此在算法设计过程中, 将全局数据复制到线程私有空间采用按行访问的形式可以保证线程束中线程访问的地址空间位于 128 字节范围内。

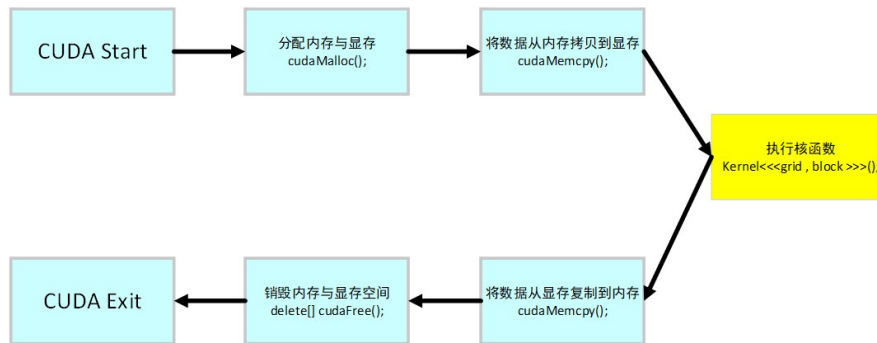


图 2.1 CUDA 执行流程

核函数的设计, 在 GPU 上所有的线程按照单指令多线程的方式去执行。不同的线程在其私有数据空间上去执行相同的指令。对于 APWF 方法, 核函数的

Algorithm 2: 并行 PWF 方法 CUDA 简化执行流程代码

```
1 cudaSetDevice();
2 cudaMemcpy2D(imgGPU, pitch imgCPU, pitch, size, n
  cudaMemcpyHostToDevice);
3 cudaStreamCreate(Stream1)
4 fPWF<<<grid,block,0,stream1>>>(parameters)
5 cudaDeviceSynchronize()
6 cudaMemcpy(resCPU,resGPU,size,cudaMemcpyDeviceToHost)
7 imshow(); Timeshow()
```

主要任务是计算极化白化滤波器参数即海杂波散射矢量的协方差矩阵的逆，协方差矩阵计算主要涉及一个 $3 \times N$ 与一个 $N \times 3$ 的矩阵相乘，对于该矩阵乘法，采用了动态并行的方式进行了进一步的优化，从当前核函数中创建新的核函数来完成矩阵并行乘法运算。得到滤波器参数后，按照式2-6生成重构强度值，并与牛顿迭代法获得的阈值做分割，输出二值检测结果图像。

2.5.2 多 GPU 协同算法设计

多 GPU 协同 APWF 方法实现，当多个 GPU 通过 PCIe 总线连接时，不同 GPU 设备之间可以进行通信与同步。多 GPU 编程中要首先确定系统中可用的 GPU 数量，之后将计算任务合理的分配到各个 GPU 上。在 APWF 算法设计中，首先为各个 GPU 设备分配设备内存，流和事件并将 SAR 图像数据从主机内存拷贝至设备内存。然后依据系统的 GPU 数量，将原 SAR 图像进行按行划分并将计算任务分配到不同的 GPU 流上。当流中的核函数执行完成后，将不同 GPU 上的检测结果复制到主机内存中，作为最终的检测结果。在多 GPU 编程实现过程中，为了便于多 GPU 之间进行通信，采用了统一虚拟寻址的技术，将所有变量映射到相同的虚拟地址空间中，方便主机和设备进行访问。

2.6 实验结果与加速比测试

本次实验在 NVIDIA TIATN V 平台上对 APWF 舰船检测方法进行测试，图2.2为海洋 SAR 图像检测结果，为了衡量 SAR 图像的检测效果，定义 $F_1 = \frac{N_{tt}}{N_{fa} + N_{gt}}$ 作为评价指标，其中 N_{tt} 为正确检测舰船目标个数， N_{fa} 为虚警的数量， N_{gt} 为数据船只的真实数量。

本次实验采用的 GPU 平台为 NVIDIA TiTan V, 相对比的 CPU 平台为 (Intel(R) Core(TM) i9-7920X CPU) 处理器, 实验所用 SAR 图像大小为 1000×1000 , 滑动的大小为 31×31。经过多次测试, 不同算法消耗时间如表2.3所示。由测试结果可知基于 GPU 的多线程 PWF 检测方法在检测效率上提升了近 32 倍, 而基于多 GPU 协同的 PWF 方法在双 GPU 的条件下检测时间性能提升了 53 倍。




图 2.2 PWF 图像检测结果

表 2.2 SAR 图像极化白化滤波器检测结果

检测方法	船只总数	总检测数量	正确检测数量	虚警数量	漏报数量	F_1
PWF	118	123	117	6	1	0.943

表 2.3 不同平台 PWF 算法运行时间

检测算法	运行平台	运行时间/s
PWF(C++)	(Intel(R) i9-7920X CPU)	67.4
GPU 多线程 PWF	GPU(Titan V)	2.1
多卡协同 PWF	2 GPU(Titan V)	1.27

2.7 小结

在本章中, 我实现了基于 GPU 的高性能并行极化白化滤波器 SAR 图像舰船目标检测算法。本章首先对自适应极化白化滤波器检测算法原理进行分析, 然

后结合 GPU 架构特点，将计算密集且可并行的滤波器参数计算部分放到 GPU 上去并行执行，并进一步将数据和计算任务分配到多 GPU 上去执行，对原算法在时间性能上进行优化。实验结果表明，相比于基于 CPU 的串行检测方法，基于 GPU 的并行检测算法在时间性能上获得了数十倍的提升。

第3章 基于混合对数正态模型 SAR 图像目标检测

3.1 引言

在使用恒虚警率的 SAR 图像目标检测方法中，对海杂波的精准建模是其中至关重要的问题。目前可以有效对海杂波建模的分布模型有瑞利分布，K 分布，威布尔分布，对数正态分布等^[?]]。在本章中我采用混合对数正态模型 (lognormal mixture model) 对强度 SAR 图像中的海杂波进行建模，实质上对数混合正态模型等价于强度 SAR 图像在对数域上的混合高斯模型^[?]]，因此可以采用 EM 方法估计分布参数，得到海杂波概率密度分布后应用牛顿迭代法计算分割阈值输出检测的结果图像

3.2 混合对数正态模型

定义强度 SAR 图像中的像素值 \mathbf{x} 为一随机变量，当其满足式3-1中的分布时，我们称随机变量 \mathbf{x} 服从包含 K 个成分的混合对数正态分布。

$$f_{\mathbf{x}}(x) = \sum_{i=1}^K \alpha_i \cdot \frac{1}{\sqrt{2\pi}\sigma_i x} \exp\left(-\frac{(\ln x - \mu_i)^2}{2\sigma_i^2}\right), x > 0 \quad (3-1)$$

在式3-1中， $\alpha_i, \mu_i, \sigma_i (i = 1, 2, \dots, K)$ 为混合对数正态分布参数，其中 α_i 为权重系数满足式3-2所示关系。混合对数正态分布为 K 个对数正态分布的加权求和。 μ_i, σ_i 为各独立的对数正态分布参数。

$$\sum_{i=1}^K \alpha_i = 1, \alpha_i \geq 0 \quad (3-2)$$

对随机变量 \mathbf{x} 做形式变换，另 $Y = \ln \mathbf{x}$ ，我们可以推导出随机变量 Y 满足的概率密度函数如式3-3所示。从式中可以判断随机变量 Y 满足含有 K 个分量的混合高斯分布，因此混合对数正太模型实际上等价于先对强度 SAR 图像取对数变换到对数域，然后应用混合高斯模型描述海杂波的分布。

$$f_Y(y) = \sum_{i=1}^K \alpha_i \cdot \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left(-\frac{(y - \mu_i)^2}{2\sigma_i^2}\right) \quad (3-3)$$

3.3 海杂波分布参数估计

3.2节表明,混合对数正态分布在强度域与混合高斯分布在对数域上等价,因此混合对数正态分布中的参数计算可以采用现有的混合高斯模型参数的计算方法。在文献^[2]中表明了对于混合高斯模型,最大期望 (EM) 算法是一种高效的估计分布参数的方法。因此在 LMM 模型参数估计中,采用 EM 算法计算海杂波分布参数。参数迭代更新方法如式3-4 所示。在该式中 $\phi(y|\mu_k, \sigma_k)$ 为均值为 μ_k , 标准差为 σ_k 的高斯分布, n 为参与估计的杂波像素数量, y 为取对数后的 SAR 图像强度值。

$$\begin{aligned} \mu_k^{i+1} &= \frac{\sum_{j=1}^n \gamma_{jk} y_j}{\sum_j \gamma_{jk}} \\ \sigma_k^{i+1} &= \sqrt{\frac{\sum_{j=1}^n \gamma_{jk} (y_j - \mu_k^{i+1})^2}{\sum_j \gamma_{jk}}} \\ \alpha_k^{i+1} &= \frac{\sum_j \gamma_{jk}}{n} \\ \gamma_{jk} &= \frac{\alpha_k^i \phi(y_j | \mu_k^i, \sigma_k^i)}{\sum_{k=1}^K \alpha_k^i \phi(y_j | \mu_k^i, \sigma_k^i)} \end{aligned} \quad (3-4)$$

受自然条件风速、风向的影响,同一 SAR 图像不同区域的杂波分布不尽相同,因此采用图3.3所示的滑动窗进行局部杂波像素的选取,该滑动窗分为三个区域分别为检测像素区域,保护区域,杂波区域。合适大小的保护区域可以减少舰船目标像素对杂波分布参数估计的干扰。选定杂波像素值后,将其代入到式3-4中进行海杂波分布参数的迭代计算。




图 3.1 滑动窗示意图

3.4 应用 LMM 模型进行 CFAR 舰船检测

当采用混合对数正态模型对海杂波分布进行建模后，根据给定的恒虚警率来实现 CFAR 检测。检测阈值通过式3-5得到，该式中 T 为恒虚警率所对应的检测阈值， $f(x)$ 为采用局部海杂波像素估计得到的概率密度函数， $F(x)$ 为 $f(x)$ 对应的累积分布函数。我们采用牛顿迭代法来解决这个非线性方程，迭代更新公式如式3-6所示，迭代停止的条件为 $|T_{i+1} - T_i| < \delta$ 。当满足迭代精度要求后，最终的检测阈值为 $T = T_{i+1}$ 。

$$P_{FA} = \int_T^{+\infty} f(x)dx = 1 - F(x) \quad (3-5)$$

$$T_{i+1} = T_i - \frac{F(T_i) + P_{FA} - 1}{f(T_i)} \quad (3-6)$$

在3.2节，我们证明了 LMM 模型等价于对数域的混合高斯模型， $f(x)$ 的概率密度函数在对数变换后可表示为式3-3 的形式。混合高斯分布的累积分布函数可以表示为式3-7。其中 $erf(x)$ 为误差函数，可以通过查表的方法来得到误差函数的值从而减少计算量。综上所述，使用混合对数正态模型的 CFAR 舰船目标检测流程如算法3所示

Algorithm 3: 基于 LMM 分布的 CFAR 舰船检测算法

Input: HH 通道强度 SAR 图像

- 1 初始化，将强度图像做对数变换得到对数域强度图像，设置滑动窗的参数。
- 2 **foreach** 图像中的像素 **do**
 - 3 从对数强度图像中根据滑动窗选择海杂波像素值 y
 - 4 采用 EM 迭代算法计算 LMM 分布参数 μ_i , α_i 与 σ_i
 - 5 根据式3-6计算检测阈值 T
 - 6 如果 $y(i, j) > T$ 则该像素点为舰船目标像素点，否则为背景杂波像素点。
- 7 **end**

Output: 二值舰船检测结果图像 *result*

$$F(x) = \frac{1}{2} \sum_{i=1}^K \lambda_k [1 + \operatorname{erf}(\frac{x - u_i}{\sqrt{2}\sigma_i})] \quad (3-7)$$

3.5 GPU 算法优化

通常应用滑动窗的 SAR 图像目标检测方法都面临着计算复杂度高，时间效率低等问题。因为不同滑动窗之间所用数据和输出结果是相互独立的，没有依赖与调用关系，所以可以将多个滑动窗的参数估计任务配到不同的 GPU 线程中去执行。

在估计 LMM 分布参数的过程中，要进行多次迭代并访问杂波像素值来更新分布参数，因此减少此部分数据的访存时间可以大幅提升算法的运行效率。对于 GPU 而言主要有以下几种存储类型，一、二级缓存、寄存器、全局内存、共享内存、纹理内存与常量内存。其中一二级缓存为不可编程的存储介质，系统运行时会自动决定缓存数据的内容与位置以获得更加优良的性能。对于可编程存储介质，每个线程的寄存器数量非常有限，因此不适合存储海杂波像素值。而全局内存、常量内存与纹理内存是板上内存，访问延迟相较于片上的共享内存要高 20 到 30 倍，因此我们选择片上的共享内存来存储滑动窗选取的海杂波数据。通过访问共享内存可以优化对全局内存的访问，从而提升核函数的执行速度。

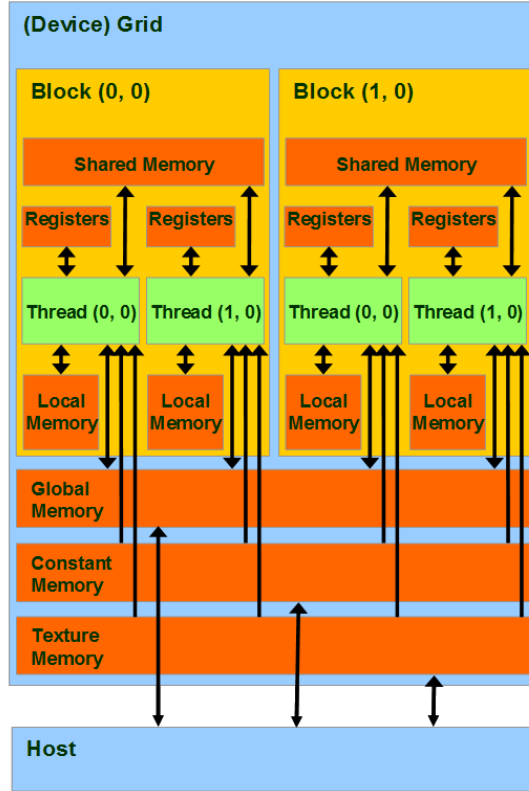


图 3.2 CUDA 内存模型

共享内存得容量非常有限，通常为 64KB。该存储空间位于流多处理器上类似于 CPU 的一级缓存，此内存空间被一个线程块中的所有线程共享。要合理的设置线程块大小，避免因共享内存空间过度使用导致活跃线程束减少从而影响程序的执行效率。结合滑动窗的大小，我们最终将线程块的大小设置为 8×8 ，将线程网格的大小设置为 $(\lfloor \frac{w+1}{8} \rfloor, \lfloor \frac{h+1}{8} \rfloor)$ 。其中 $\lfloor \cdot \rfloor$ 代表向下取整， w 代表 SAR 图像的宽度， h 代表 SAR 图像的高度。

在分配好线程块与线程网格大小后，每个线程索引与 SAR 图像像素索引对应关系为： $\text{row} = \text{threadIdx.x} + \text{blockDim.x} * \text{blockIdx.x}$; $\text{column} = \text{threadIdx.y} + \text{blockDim.y} * \text{blockIdx.y}$; 之后根据滑动窗，将检测像素所对应的海杂波像素复制到该线程所对应的共享内存内存空间中。EM 算法实现，从共享内存中读取杂波像素值进行分布参数的迭代更新，当满足迭代停止条件后得到 LMM 的分布参数。应用 CFAR 检测器进行舰船检测，根据 LMM 分布采用牛顿迭代法计算检测阈值 T ，当待检测像素值大于阈值 T 时，该像素被标记为舰船目标像素。在所有线程执行完毕后，主机将检测结果从设备内存拷贝至主机内存做进一步的分析与处理。




图 3.3 CUDA 线程与检测像素映射关系

3.6 LMM 实验结果

本次实验中我们使用的是由星载成像雷达系统 (SIR-C/X) 得到的香港维多利亚港的 SAR 图像数据。截取的部分 HH 通道强度图像如图3.4所示




图 3.4 四张局部 SIR-C/X HH 通道强度图像

在实验中我们设置恒虚警为 1×10^{-5} ，检测结果如图3.5所示，其中白色区域代表舰船目标像素区域，黑色区域代表背景杂波区域，从结果可以看出在给定

的虚警率下，LMM 算法对目标像素与舰船像素作做出了正确的分割。本次实验使用的 GPU 为 NVIDIA TITAN V，经过多次实验验证，相较于使用单线程 CPU 的检测方法，程序运行的时间效率提升了近 21 倍，不同平台运行时间如表所示。因原始 SAR 图像中的舰船数量较少，检测结果中虚警漏报的数量均为 0，准确率达到 100%。




图 3.5 LMM 检测结果

表 3.1 串行与并行 LMM 算法运行时间对比

检测算法	运行平台	运行时间/s
LMM-CFAR(Matlab 单线程)	(Intel(R) i7-9750H CPU)	37.5
LMM-CFAR(GPU 多线程)	GPU(Titan V)	1.73

3.7 小结

本章我们实现了基于混合对数正态分布的 SAR 图像舰船检测方法，在本质上混合对数正态分布等价于强度 SAR 图像在对数域上的混合高斯分布，因此采用了 EM 算法与牛顿迭代法得到分布参数与检测阈值。对于滑动窗参数估计的

部分，我们将其放置在 GPU 上进行并行计算，并使用延迟更低的共享内存来加快访存速度。相较于传统的串行解决方案，本章基于 GPU 的 LMM 方法不仅在时间性能获得了显著的提升同时还保证了检测结果的精度。

第 4 章 基于 PCDM 的极化 SAR 图像舰船目标检测

4.1 引言

在第2章与第3章，我们实现了基于 PWF 与 LMM 模型的舰船检测算法，这两种方法都是对图像强度信息进行统计建模以区分舰船目标与背景杂波。然而基于强度或幅值的统计方法易受海况的影响导致对海杂波的拟合程度不够精确，使得检测性能下降。在本章中我们实现了基于极化协方差差异矩阵的极化 SAR 舰船目标检测方法。在极化 SAR 图像中，舰船目标点的邻域像素提供了丰富的空间相干信息，极化协方差矩阵主要度量了待检测像素与其 3×3 邻域像素的协方差矩阵的差异。基于该极化差异矩阵，我们首先应用 SPAN 检测器得到了粗略的舰船检测结果。同时我们将 PCDM 矩阵进行极化分解提取了新的极化特征基础船高 (PSH)，通过此极化特征结合 SPAN 检测器给出的初步检测结果进行综合判断得到最终的舰船检测结果。

4.2 PCDM 理论背景

4.2.1 极化 SAR 散射表征与 SPAN 理论

通常散射矩阵被用来描述目标散射体的极化信息。在使用水平与垂直极化基的典型极化 SAR 系统中，复散射矩阵定义为如下的形式^[2]，其中 S_{HH} 代表了水平发射水平接收的极化信息，当满足互易性的条件时， $S_{HV} = S_{VH}$ 此时复散射矩阵可用三维的复散射矢量 k 表示，如式4-2所示。

$$S = \begin{bmatrix} S_{HH} & S_{HV} \\ S_{VH} & S_{VV} \end{bmatrix} \quad (4-1)$$

$$k = [S_{HH}, \sqrt{2}S_{HV}, S_{VV}] \quad (4-2)$$

将散射矩阵进行变换可以得到更多散射体的极化信息，式4-3为散射矢量对应的极化协方差矩阵^[2]。在该式中 $\langle \rangle$ 代表在空间域上求平均， $||$ 代表幅度值， H 代表共轭转置。

$$[C] = \langle k \cdot k^H \rangle = \begin{bmatrix} C_{11} & C_{12} & C_{13} \\ C_{21} & C_{22} & C_{23} \\ C_{31} & C_{32} & C_{33} \end{bmatrix} \quad (4-3)$$

在极化协方差矩阵 C 中，将对角线元素之和定义为后向散射总功率即 SPAN，如式4-4所示。还可以对极化协方差矩阵进行分解如式4-5所示^[7]，其中 λ_i 为极化协方差矩阵特征值， v_i 为 λ_i 对应的特征向量。

$$\text{SPAN} = C_{11} + C_{22} + C_{33} \quad (4-4)$$

$$C = \sum_{i=1}^3 \lambda_i (v_i \cdot v_i^H) \quad (4-5)$$

4.2.2 极化协方差差异矩阵

在计算机视觉领域，LBP 特征 (局部二值模式) 用来描述光学图像中的纹理特征，被广泛应用于人脸检测与目标识别。LBP 特征是将一个 3×3 区域内的中心像素值与邻域像素值做比较，并将得到的八位二进制结果重新排列构成一新二进制数值，该数值作为此区域中心像素的 LBP 特征值，如式4-6所示，其中 g_i 表示邻域内第 i 个像素的灰度值， g_c 为中心像素灰度值， x_c, y_c 表示中心像素坐标。

$$[LBP_{(x_c, y_c)}] = \sum_{i=0}^{n-1} 2^{is(g_i - g_c)}, s(x) = \begin{cases} 1 & x \geq 0 \\ 0 & x < 0 \end{cases} \quad (4-6)$$

类比光学图像中的 LBP 特征^[7]，在极化 SAR 图像中，采用极化协方差矩阵来描述图像的极化信息。在光学图像中像素的灰度值可以通过 R、G 和 B 三个通道进行计算得到，而极化协方差矩阵也包含了极化 SAR 图像的 HH、HV 和 VV 通道的信息，但区别是灰度值只含有图像的一个特征，而极化协方差矩阵包含了九个极化特征，因此对 LBP 模型进行改进引入极化协方差差异矩阵 (PCDM)

定义 $C^{(x,y)}$ 为极化 SAR 图像索引为 x, y 像素处的极化协方差矩阵，接下来计算其 3×3 邻域上的协方差矩阵累积差异 $P^{(x,y)}$ ，称 $P^{(x,y)}$ 为极化 SAR 图像 (x, y) 处的极化协方差差异矩阵^[7] 如式4-7所示，其中 $C_{m,n}^{(i,j)}$ 为图像 (i, j) 处像素对应协方差矩阵的第 (m, n) 个元素。

$$P_{m,n}^{(i,j)} = \sum_{\Delta i=-1, \Delta j=-1}^1 \left| C_{m,n}^{(i,j)} - C_{m,n}^{(i+\Delta i, j+\Delta j)} \right| \quad (4-7)$$




图 4.1 PCDM 矩阵计算示意图

4.3 基于 PCDM 的舰船目标检测算法

前两节我们描述了 PCDM 可以综合利用待检测像素与其邻域的像素的空间相干信息，在此基础上我们提出了基于极化协方差差异矩阵的舰船检测方法。对于输入的原始极化 SAR 图像数据，我们首先计算每个像素的极化协方差矩阵，然后按照式4-7计算每个像素对应的极化协方差差异矩阵。得到极化协方差差异矩阵 \mathbf{P} 后，首先对 \mathbf{P} 矩阵应用 SPAN 检测器，即当 $\text{SPAN}_{\mathbf{P}} > T_{\text{SPAN}}$ 时，认定该检测像素为舰船目标像素。

对 PCDM 矩阵应用 SPAN 检测器后输出初步检测结果，为了提升检测的精度，我们进一步提取极化协方差差异矩阵的极化特征来区分舰船目标与背景杂波。通常 SAR 图像目标散射特性可以用极化特征来描述，例如极化分解，极化反对称性等极化特征。在文献^[2]中提出了 pedestal height 特征来描述目标的散射特性，该极化特征实质上等价于极化协方差矩阵最小特征值与最大特征值的比值，实验表明低海况下的背景杂波与方位向模糊像素的 pedestal height 极化特征值比真实的舰船像素要低很多。

$$\text{PSH} = \frac{|\lambda_3|}{|\lambda_1| + |\lambda_2|} \quad (4-8)$$

基于极化协方差差异矩阵我们重新计算这些极化特征，并将第二特征值考

Algorithm 4: 基于 PCDM 的舰船检测算法

Input: 原始极化 SAR 图像数据

- 1 初始化，计算每个像素的协方差矩阵。
- 2 **foreach** 图像中的像素 **do**
 - 3 根据协方差矩阵计算该像素对应的极化协方差差异矩阵
 - 4 计算该极化协方差差异矩阵的 SPAN 值
 - 5 计算极化协方差差异矩阵的基础船高 (PSH) 极化特征
 - 6 将差异矩阵 SPAN 值与经验阈值作比较，如果 $SPAN_{PCDM} > T_{SPAN}$ ，
则将该像素为舰船像素。
 - 7 将极化特征 PSH 与经验阈值作比较，如果 $PSH_{P(x,y)} > T_{PSH}$ ，则该
像素为舰船像素
- 8 **end**

Output: 最终舰船检测结果 *result*

虑在内，新的极化特征命名为 pedestal ship height(PSH)。对于提取的 PSH 极化特征，应用适当的检测阈值，来区分舰船目标与背景杂波像素。整个算法的流程如图4.2所示，算法描述如算法4所示




图 4.2 PCDM 检测流程示意图

4.4 基于 GPU 的 PCDM 算法设计

前几节描述了基于极化协方差差异矩阵的舰船目标检测算法，在该方法中需要对计算 SAR 图像每一个像素对应的协方差差异矩阵及其极化特征 PSH。在该方法中不同像素对应的极化协方差差异矩阵不同，且极化特征估计相互独立，因此将对每个像素的检测操作一一对应到 GPU 上的每个线程。

线程模块大小设计，本次实验使用的原始 SAR 图像数据大小为 1000×1000 。在流多处理器中线程块中的线程以 32 个为一组进行调度，为充分利用流多处理器资源，将线程块大小设计为 32×32 。考虑到 GPU 同时并发线程数量的限制与全局内存空间容量，将线程网格大小设计为 16×16 ，对于线程块中的线程通过其二维线程索引 (threadIDx) 与原始 SAR 图像上的列一一对应，使用线程块索引 (blockIDx) 与原始 SAR 图像的行去对应。我们设计的线程网格数量为 256 小于原始 SAR 图像的行数，因此对 SAR 图像的检测操作将被分配到四个内核中去执行。内核中的线程通过内核序号来找到自己对应的 SAR 图像行索引，四个内核被装载到同一 CUDA 流中在 GPU 上被顺序调度。线程内存空间设计，在 CUDA 架构中不能在核函数中去动态声明较大的内存区域，因此需要在内核执行前由主机分配好线程内存池，然后线程根据自身索引与给定的线程空间大小去找到本线程私有内存空间的起始地址。线程内存空间分析，对于 PCDM 方法，要存储九个像元的散射矩阵信息、协方差矩阵信息与中心像元的极化协方差差异矩阵，综合考虑 PCDM 矩阵计算特征值等其他计算开销，最终我们将一个线程所占用的内存空间设置为 8192B。

内核函数的设计，首先计算本线程所对应的二维索引，将该二维索引与其 3×3 邻域对应的 SAR 图像数据从全局内存复制到线程私有的内存空间中，之后计算这九个像元所对应的协方差矩阵并调整为 9×9 大小，该矩阵每一列代表各像元的协方差矩阵元素。将该矩阵的第五列即中心像素的协方差矩阵与其他列依次做差求绝对和得到极化协方差差异矩阵。计算得到 PCDM 矩阵后，首先对该矩阵应用 SPAN 检测器，即计算矩阵对角线元素之和并与经验阈值做比较，当该 SPAN 值大于经验阈值时，将该像素判别为舰船像素。接下来计算极化协方差差异矩阵的 PSH 极化特征，该特征为 PCDM 矩阵最小特征值与其他两个特征值绝对值之比，因此问题转化为计算极化协方差差异矩阵特征值的问题。PCDM 矩阵为实对称矩阵，计算其特征值采用雅克比迭代的方法，迭代过程的矩阵更新公式如式4-9所示，其中 φ 通过选择矩阵非对角绝对值最大元素计算得到。具

体的算法流程如算法5所示。得到矩阵的特征值后计算 PSH 极化特征的大小并与经验阈值做比较，如果 PSH 值大于经验阈值，则判断该像素为舰船目标像素。当 GPU 上所有线程核函数执行结束后，主机将检测结果从设备内存拷贝至主机内存，结合 OpenCV 进行图像显示，并保存检测结果。

$$\begin{cases} a_{pp}^{i+1} = a_{pp}^i \cos^2 \varphi + a_{qq}^i \sin^2 \varphi + 2a_{pq}^i \cos \varphi \sin \varphi \\ a_{qq}^{i+1} = a_{pp}^i \cos^2 \varphi + a_{qq}^i \sin^2 \varphi - 2a_{pq}^i \cos \varphi \sin \varphi \\ a_{pq}^{i+1} = a_{qp}^{i+1} = \frac{1}{2}(a_{qq}^i - a_{pp}^i) \sin 2\varphi + a_{pq}^i \cos 2\varphi \end{cases}$$

$$\begin{pmatrix} a_{pn}^{i+1} \\ a_{qn}^{i+1} \end{pmatrix} = \begin{pmatrix} \cos \varphi & \sin \varphi \\ -\sin \varphi & \cos \varphi \end{pmatrix} \begin{pmatrix} a_{pn}^i \\ a_{qn}^i \end{pmatrix}, n \neq p, q \quad (4-9)$$

$$\begin{pmatrix} a_{mp}^{i+1} \\ a_{mq}^{i+1} \end{pmatrix} = \begin{pmatrix} \cos \varphi & \sin \varphi \\ -\sin \varphi & \cos \varphi \end{pmatrix} \begin{pmatrix} a_{mp}^i \\ a_{mq}^i \end{pmatrix}, m \neq p, q$$

$$a_{mn}^{i+1} = a_{nm}^{i+1} = a_{mn}^i, m \neq p, q; n \neq p, q$$

$$\tan 2\varphi = \frac{-2a_{pq}}{a_{qq} - a_{pp}} \quad (4-10)$$

Algorithm 5: 雅克比迭代计算矩阵特征值


Input: 实对称矩阵 **A**

- 1 初始化特征向量为单位阵。
 - 2 **while** **A** 非主对角元素绝对值 < 给定阈值 **do**
 - 3 在 **A** 的非主对角元素中找到最大元素值为 a_{pq}
 - 4 用式4-10计算旋转角度 φ
 - 5 用式4-9来对矩阵 **A** 中的元素进行更新
 - 6 **end**
 - 7 将矩阵特征值按照从大到小的顺序进行排序 **Output:** 矩阵 **A** 的特征值
-


4.5 PCDM 算法检测结果

在本次实验中我们使用的是 Radarsat-2 远洋极化 SAR 数据，通常舰船目标相对于海平面的后向散射系数更高，具有更高的散射回波功率，因此舰船像素的

SPAN 值要高于海杂波像素。PCDM 方法充分利用了检测像素与其邻域像素的空间相干关系，基于 PCDM 的 SPAN 图像可以提升船海之间的对比度，有着更强的鉴别舰船与海杂波的能力，图4.1为原数据局部切片的 SPAN 图像与 PCDM SPAN 图像的对比。实验结果表明，基于 PCDM 的 SPAN 值相较于基于协方差矩阵的 SPAN 值船海对比度更加明显。最终我们选取 PCDM SPAN 最大值与最小值差的千分之五作为分割阈值，从而区分舰船目标与背景杂波。



(a) PCDMSPAN 图



(b) SPAN 图像

图 4.3 PCDNSPAN 图像与 SPAN 图像对比

图像检测结果，本次实验所使用的 GPU 为 TiTAN V，运行显存内存为 12G。基于 MATLAB 的串行方法使用的 CPU 为 Intel(R) i7-9750H，系统内存为 16G。为了验证检测结果的有效性，我们将 PCDM 方法与第二章实现的 PWF 方法进行对比如图4.4所示，从左到右依次为 SPAN 图像，PWF 检测结果，PCDM 检测结

果。从检测结果上来看，PCDM 得到的舰船检测结果与 Pauli 图像更加吻合，舰船边缘相较于 PWF 方法检测结果更加精确。算法的检测性能使用第二章定义的品质因数 F_1 即正确检测数量与虚警数量和船只真实数量之和的比值来表示。检测结果如表4.1所示，PCDM 的检测的品质因数高于 PWF 检测方法，可以得出结论 PCDM 算法对于复杂海况的适应能力比 PWF 强，即使面对不同海况依然可以保持高检测精度。

在 PCDM 方法中不需要使用大量的海杂波像素去估计滤波器参数，该算法主要是计算大小为 3×3 的极化协方差差异矩阵及其特征值，因此算法在时间与空间性能上都优于极化白化滤波器方法。CPU 串行与 GPU 并行的 PCDM 算法所用时间如表所示，因为 GPU 设备初始化开销代价所占比重较大，且 CPU 与 GPU 之间需要进行数据拷贝、通信与同步，所以本身在 CPU 上运行时间较短的程序在 GPU 上的加速比会降低。对于大小为 1000×1000 的 SAR 图像，经过多次实验测试，并行 PCDM 算法在 Titan V 上的运行的平均时间为 0.69s，串行 MATLAB 方法在 CPU 上的运行时间为 11.37 秒，在时间性能上获得了近 17 倍的提升。

表 4.1 SAR 图像检测结果对比

检测方法	船只数量	总检测数量	正确检测数量	虚警数量	漏报数量	F_1
PCDM	118	120	117	3	1	0.967
PWF	118	123	117	6	1	0.943

表 4.2 不同平台算法运行时间对比

检测算法	运行平台	运行时间/s
PCDM(MATLAB)	(Intel(R) i7-9750H CPU)	11.4
GPU 并行 PCDM	GPU(Titan V)	0.67
PWF(C++)	(Intel(R) i9-7920X CPU)	67.4
GPU 多线程 PWF	GPU(Titan V)	2.1
多卡协同 PWF	2 GPU(Titan V)	1.27




图 4.4 舰船检测结果 (a)SPAN 图像;(b)PWF;(c)PCDM

4.6 小结

对于极化 SAR 图像中的舰船目标检测，在本章我们实现了基于极化协方差差异矩阵的舰船检测方法。在该方法中，类比于光学图像检测中的 LBP 特征，我们引出了极化 SAR 图像的极化协方差差异矩阵 (PCDM) 的概念，PCDM 矩阵计算了待检测像素与邻域像素的协方差矩阵差异，充分利用了空间相干信息，提高了舰船目标与背景杂波之间的对比度。接下来我们将 PCDM 矩阵应用于舰船检测，首先使用 PCDM 矩阵的 SPAN 值对船海像素做了一个粗略的划分，然后提取了 PCDM 矩阵的 PSH 极化特征，将该特征用于舰船目标检测，最后联合 SPAN

检测器得到的初步检测结果得到了最终的检测结果。实验结果表明 PCDM 方法可以有效的适应不同的复杂海况，相较于 PWF 算法，在检测精度、时间与空间性能上都优于 PWF 算法。最后我们实现了基于 GPU 的并行 PCDM 方法，将图像像素对应的 PCDM 矩阵与 PSH 极化特征计算对应到每一个 GPU 线程中去并发执行。相比于串行执行的方式，并行的方法在时间性能上提升了近 20 倍，可以满足实时检测的要求

第 5 章 总结与展望

本文针对极化 SAR 图像目标检测算法中存在的计算量大，耗时长等问题提出了基于 CPU+GPU 异构架构的解决方案。本文详细的分析了几种典型的基于分布和基于极化分解的 SAR 图像舰船检测方法，并分离其中可并行执行的部分，实现了基于 GPU 的并行 SAR 图像舰船检测方法，本文完成的工作和创新点主要包括：

1) 实现了基于 GPU 的极化白化滤波器极化 SAR 舰船目标检测算法，采用 GPU 多线程并行计算滑动窗内海杂波对应的极化白化滤波器参数，并计算分割阈值得到检测结果。此外还合理的将数据与任务分配到了多块 GPU 上同时并行计算，使得算法在时间效率进一步提升。2) 实现了基于 GPU 的 LMM 舰船检测方法，该算法将估计海杂波分布参数的部分附加到 GPU 上执行，并对参数迭代的过程使用 GPU 共享内存进行优化，实验结果表明基于 GPU 的 LMM 算法在时间性能上获得了数十倍的提升。3) 实现了基于 GPU 的 PCDM 舰船检测方法，该算法将 PCDM 矩阵与提取 PCDM 矩阵极化特征的计算部分放在 GPU 上并行计算。并行算法在检测时间效率上获得了数十倍的提升，并且对复杂海况具有很好适应性。

本文在基于 GPU 的极化 SAR 图像检测上取得一定的成果，但是受限于时间、数据等原因，未来的工作还可以在以下几个方面展开：

1) 在 PCDM 检测方法中，本文对于极化协方差差异矩阵的 SPAN 值与 PSH 特征采用经验阈值进行分割，可以尝试对这两个极化特征进行统计分析以得到更加精准的自适应阈值，从而提升算法的检测精度。2) 受限于 CUDA 提供的 MATH API，较难实现 Gamma 分布，K 分布等其它海杂波统计模型，之后可以探究可在 GPU 上运算的更多统计分布模型，从而对海杂波分布拟合结果更加精准。3) 算法基于 linux 系统下的 CUDA 运行环境进行设计，并没有针对 SAR 系统实际的硬件环境来设计，未来可以结合含有嵌入式的 GPU 的 SAR 图像处理系统对算法在接口，时间，内存，功耗上做进一步的优化。

插图索引

图 1.1	CPU 和 GPU 浮点运算比较	2
图 1.2	论文内容安排	5
图 2.1	CUDA 执行流程	10
图 2.2	PWF 图像检测结果	12
图 3.1	滑动窗示意图	16
图 3.2	CUDA 内存模型	18
图 3.3	CUDA 线程与检测像素映射关系	19
图 3.4	四张局部 SIR-C/X HH 通道强度图像	19
图 3.5	LMM 检测结果	20
图 4.1	PCDM 矩阵计算示意图	24
图 4.2	PCDM 检测流程示意图	25
图 4.3	PCDNSPAN 图像与 SPAN 图像对比	28
图 4.4	舰船检测结果 (a)SPAN 图像;(b)PWF;(c)PCDM.....	30
图 A-1	RADASAT-2 极化 SAR 图像 (a) 新加坡海峡 (b) 大连港	48

表格索引

表 2.1	不同强度图像 s/m 比值	8
表 2.2	Adaptive PWF 检测结果	12
表 2.3	PWF 不同平台运行时间	12
表 3.1	LMM 算法时间	20
表 4.1	PCDM 检测结果	29
表 4.2	PCDM 算法运行时间对比	29
表 A-1	极化 SAR 图像参数	48

公式索引

公式 2-1	6
公式 2-2	6
公式 2-3	7
公式 2-4	7
公式 2-5	7
公式 2-6	7
公式 2-7	8
公式 2-8	8
公式 2-9	9
公式 2-10	9
公式 3-1	14
公式 3-2	14
公式 3-3	15
公式 3-4	15
公式 3-5	16
公式 3-6	16
公式 3-7	17
公式 4-1	22
公式 4-2	22
公式 4-3	23
公式 4-4	23
公式 4-5	23
公式 4-6	23
公式 4-7	24
公式 4-8	24
公式 4-9	27
公式 4-10	27
公式 A-1	41

公式 A-2	41
公式 A-3	41
公式 A-4	41
公式 A-5	42
公式 A-6	42
公式 A-7	43
公式 A-8	43
公式 A-9	43
公式 A-10	43
公式 A-11	44
公式 A-12	44
公式 A-13	44
公式 A-14	44
公式 A-15	45
公式 A-16	45
公式 A-17	45
公式 A-18	45
公式 A-19	45
公式 A-20	45
公式 A-21	46
公式 A-22	46
公式 A-23	46
公式 A-24	46
公式 A-25	46
公式 A-26	47
公式 A-27	47

致 谢

衷心感谢我的导师杨健教授在本次毕业设计中对我的精心指导和帮助。杨老师是我的班主任，这四年的大学生活中他在学习与科研工作等方面对我提出了很多针对性的建议和帮助。进入实验室的这一年时间，在与老师与学长的交流中，我的科研能力获得了很大的提升。

感谢金侃、王洪淼、林惠平、朱庆涛、陈航、张涛等师兄对我毕业设计的指导和帮助，当我面临算法设计上的困难时感谢你们的建议让我获得了获得了更多的知识与更宽广的设计思路。

感谢我的父母，感谢他们一直的辛勤付出与支持。因为疫情，此次毕设大部分工作都在家中完成，感谢他们这段时间在生活上对我的关心与照料。

声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名：_____ 日 期：_____

附录 A 外文资料的调研阅读报告或书面翻译

基于变分贝叶斯推断的极化 SAR 舰船检测

摘要：在本文中，我们创新的提出了一种基于变分贝叶斯推断的极化 SAR 图像舰船检测方法。首先我们将极化 SAR 图像表示为一个张量，并且将 SAR 图像分解为与舰船有关的稀疏分量和海杂波分量的总和。这些成分由一些潜在变量表示。之后我们介绍了潜在变量的层次先验并建立了舰船检测的概率模型。通过变分贝叶斯推断的方法，我们计算得到潜变量的后验分布。最后在迭代贝叶斯推断过程中获得舰船检测结果。本文提出的方法采用张量的形式表示极化 SAR 图像，显式的使用了 SAR 图像所有通道的极化信息从而避免了采用标量极化特征表示可能导致的信息丢失。此外本文提出的方法不需要使用滑动窗，变分贝叶斯推断过程实际上使用了所有的像素而不是滑动窗内有限的像素，因此该方法具有良好的舰船检测性能和目标形状保持能力，适用于拥挤海域的舰船检测。本次实验采用了 C 波段 radarsat-2 极化 SAR 数据，实验结果表明方法可以实现最先进的舰船检测性能。

A.1 介绍

基于 SAR 图像的舰船检测在渔业、海上交通服务与海上安全等领域都有十分重要的应用。相较于传统的单极化 SAR 舰船检测，极化信息的加入可以显著提升舰船检测结果的精度。举例来讲，在仅使用交叉极化通道 (HV) 的 SAR 图像检测中，在入射角为陡峭和中等的条件下可以获得令人满意的结果，而同极化 (HH 或 VV) 需要更大角度入射角才能表现的较好。这些方法都不需要复杂的极化信息融合方法。

对于多通道 SAR 图像，通常设计一个标量特征来增强船海对比度，然后将全局阈值或恒虚警率检测器应用于该标量特征。CFAR 检测通常使用滑动窗来估计局部海杂波参数，然后根据虚警率计算分割像素值。类似单极化 SAR 舰船检测中的图像强度。散射总功率 SPAN(散射矩阵 F 范数的平方) 被自然的作为极化特征。更多复杂的极化特征设计实质上都是极化信息融合方法，这些方法可以大致分为两大类，基于单视散射矩阵与基于多视协方差矩阵或相干矩阵的

方法。对于第一类，Jeremy 通过使用 Cameron 分解实现了舰船检测。Touzi 提出了基于堆成散射特性的方法。Nunziata 使用共极化与交叉极化通道散射相关性来检测船只。Novak 提出了极化白化滤波器，通过融合散射矩阵的各个元素来生成一幅相干斑抑制图像。尽管这些方法在足够大的信杂比 (SCR) 的条件下检测效果较好，但他们更容易受到变电噪声的影响，从而增加小型舰船的虚警率。对于第二类，Yang 提出了广义优化极化对比增强 (GOPCE) 来最大化图像的信杂比。Chen 介绍了基于极化相干矩阵分解的极化交叉熵，并通过广义指数分布近似模拟海杂波的 PCE 值。Armando 提出了一种基于几何扰动极化陷波滤波器 (GP-PNF) 的检测器，并推导了滤波值的概率密度分布函数。Touzi 使用极化度 (Dop) 和最小极化度的偏移来改善船海对比度。在这些方法中，通过空间整体平均来抑制斑点噪声，但是这种空域平均操作不利于检测小型船只。

在多极化 SAR 舰船检测的实际应用中，上述提到的标量特征 CFAR 检测器有两个缺点：1) 尽管标量隐含了不同通道的贡献，但是显示使用所有极化通道应该可以提供更多的信息，而标量标识没有有效利用它。另外特征标量的理论分布较难分析，或者估计分布参数及其复杂。2) 在多目标情况下，尤其是在拥挤的海域，不适合的滑动窗大小将会导致对海杂波分布参数的错误估计，因此舰船检测性能将会下降。尽管顺序统计与其他的检测方法被提出来解决这一问题，但在实践中仍然存在很多困难，例如先验依赖，计算复杂，应用场景限制等。

为了克服这些缺点，我们提出同时利用海面的低秩特性与舰船的稀疏特性。我们采用多维广义低秩模型和鲁棒主成分分析进行极化 SAR 图像舰船检测。尽管在这些方法中没有使用极化数据融合与滑动窗，但是海平面的低秩特性是一个太严格的约束限制了这些方法的实际应用。因此在单极化 SAR 舰船检测中，我们去除了低秩约束的限制仅利用了舰船的稀疏特性并采用了变分贝叶斯推断的方法用于 SAR 图像舰船检测，该方法实现了最先进的舰船检测性能。为了进一步处理多通道 SAR 图像舰船检测并充分利用极化信息，在 IEEE IGARSS 2016 中我们提出将极化 SAR 图像与变分贝叶斯推断相结合。在本文中我们将提供有关该方法的更多详细信息，并将其与最新的舰船检测方法进行比较以证明其有效性。因此本文是第一个正式致力于使用变分贝叶斯推断进行极化 SAR 图像舰船检测的工作。首先我们将多通道的极化 SAR 图像表示为张量，并介绍了与之相关的多维变量的先验分布。因此我们没有应用极化信息融合而是提出了一个应用变分贝叶斯推断进行极化 SAR 图像舰船检测的通用框架。其次我们进一步改善了舰船检测的概率模型，减少了隐变量的个数，简化了变分贝叶斯推断的

过程。

本文的其余部分安排如下。第二章介绍了极化 SAR 图像中舰船检测的精准概率模型。第三节详细介绍了将变分贝叶斯推断应用于舰船检测。第四节报告了实验结果。第五部分总结了本文的工作。

A.2 极化 SAR 图像概率模型

此前我们提出了单通道 SAR 图像的舰船检测概率模型。在本文中，我们将此基本模型扩展到极化 SAR 图像。我们将极化 SAR 图像定义为张量进而完善了此前提出的原始概率模型并引入适用的多元隐变量先验分布。

A.2.1 极化 SAR 图像表示

对于单极化 SAR 图像，像素值由图像强度定义。对于全极化单视复图像，像素的复散射矢量在非互易的条件下定义如A-1 所示。

$$\begin{aligned} \mathbf{w} &= \begin{bmatrix} S_{HH} & S_{HV} & S_{VH} & S_{VV} \end{bmatrix}^T && \text{linear basis} \\ \mathbf{w} &= \frac{1}{\sqrt{2}} \begin{bmatrix} S_{HH} + S_{VV} & S_{HH} - S_{VV} & S_{HV} + S_{VH} & j(S_{HV} - S_{VH}) \end{bmatrix} && \text{Pauli basis} \end{aligned} \quad (\text{A-1})$$

其中 $S_{HH}, S_{HV}, S_{VH}, S_{VV}$ 定义了水平-垂直基下的散射矩阵元素。上标 T 为转置。在满足互易的情形下如式A-2所示

$$\begin{aligned} \mathbf{w} &= \begin{bmatrix} S_{HH} & \sqrt{2}S_{HV} & S_{VV} \end{bmatrix}^T && \text{linearbasis} \\ \mathbf{w} &= \frac{1}{\sqrt{2}} \begin{bmatrix} S_{HH} + S_{VV} & S_{HH} - S_{VV} & 2S_{HV} \end{bmatrix} && \text{Paulibasis} \end{aligned} \quad (\text{A-2})$$

在这里，我们进一步将复散射矢量 \mathbf{w} 表示为实向量 \mathbf{d} 的形式，如式A-3所示。其中 d 为三或四对应互易或者非互易的情形。

$$\mathbf{d} = [\text{Re}(\mathbf{w}_1)\text{Im}(\mathbf{w}_1) \cdots \text{Re}(\mathbf{w}_d)\text{Im}(\mathbf{w}_d)] \quad (\text{A-3})$$

在 SAR 图像中，海杂波像素值是随机变化的，舰船显示为稀疏分布的目标像素具有显著的稀疏特征。因此使用张量术语我们可以将舰船检测视为从海杂波中恢复稀疏信号的问题，其中采用张量表示的极化 SAR 图像可以被建模为

$$\mathbf{D} = \mathbf{A} * \mathbf{S} + \mathbf{C} \quad (\text{A-4})$$

$\mathbf{D} \in \mathbb{R}^{m \times n \times 2d}$, $\mathbf{A} \in \mathbb{R}^{m \times n \times 2d}$, $\mathbf{C} \in \mathbb{R}^{m \times n \times 2d}$ 分别代表 SAR 图像, 严格稀疏的舰船成分, 海杂波成分。Tube fiber 定义为有固定行列索引的实向量如式A-3的形式。 $\mathbf{A} \in \mathbb{R}^{m \times n \times 2d}$ 的所有正面切片均为相同的二进制数值矩阵 $\mathbf{A} = [\mathbf{a}_{ij}] \in \mathbb{R}^{m \times n}$ 其中第 (i, j) 个元素 $a_{ij} = 1$ 表示该像素为舰船像素。故将矩阵 \mathbf{A} 视为舰船检测结果。 $\mathbf{S} \in \mathbb{R}^{m \times n \times 2d}$ 是非严格稀疏的舰船分量矩阵, $*$ 表示哈达玛积。在这我们定义 $d_{ij:}$, $s_{ij:}$, $c_{ij:}$ 为张量 $\mathbf{D}, \mathbf{S}, \mathbf{C}$ 的 tube fiber。

现在值得花一些时间去研究式A-4的形式, 因为它可以提供模型细化的一些观点。从式A-4中我们可以看出当 $a_{ij} = 1$ 时, $d_{ij:} = s_{ij:} + c_{ij:}$ 。当 $a_{ij} = 0$ 时, $d_{ij:} = c_{ij:}$ 。因为舰船检测的目的是估计二进制潜变量 \mathbf{A} 而不是 \mathbf{S} , 因此当 $a_{ij} = 1$ 时, 我们可以进一步约束 $c_{ij:} = \mathbf{0}$, 因此 \mathbf{S} 实际上是 \mathbf{D} , 式A-4可以表示为

$$\mathbf{D} = \mathbf{A} * \mathbf{D} + \mathbf{C} \quad (\text{A-5})$$

在本文中, 我们使用这个改进的方法来表示 SAR 图像, 并通过变分贝叶斯推断估计了隐变量 \mathbf{A} 与 \mathbf{C} 。相比于文献 [21] 中的分析, 概率模型与变分贝叶斯推断的过程在本文中都进行了改进。为了提升模型对复杂场景中的稀疏舰船成分的检测能力, $a_{ij}, c_{ij:}$ 的独立先验定义如下。

A.2.2 稀疏分量 \mathbf{A} 的先验分布

将二进制标记系数 a_{ij} 建模为相同的分布即

$$\begin{aligned} p(a_{ij}|e_{ij}) &= e_{ij}^{a_{ij}} (1 - e_{ij})^{1-a_{ij}} \\ P(e_{ij}) &= \text{Beta}(\alpha_0, \beta_0) \end{aligned} \quad (\text{A-6})$$

其中 e_{ij} 代表了舰船像素的存在概率, $\alpha_0 > 0, \beta_0 > 0$ 为超参数。Beta(\cdot) 为 Beta 分布。因此 e_{ij} 的期望 $E(e_{ij})$ 为 $\frac{\alpha_0}{\alpha_0 + \beta_0}$ 并且 $E(a_{ij})$ 接近 0。在这种情形下, 稀疏条件加于 \mathbf{A} 上。为了简化分析我们让 $\alpha_0 \ll 0$ 并限制 $\alpha_0 + \beta_0 = 1$ 。需要注意的是 α_0, β_0 并不依赖于其他参数并且他们被设置为确定性的值, 下节的其他超参数也是如此。

A.2.3 海杂波 \mathbf{C} 的先验分布

在一些强风或暴雨海域的场景中, 整张图像海杂波的统计特性在空间上是变化的, 因此海杂波的分布可能不再是单峰的。此外混合高斯分布可以近似估计一个连续的概率密度分布, 因此为了更好的拟合海杂波分布, 我们使用包含

K 个分量的混合多元高斯分布来对 c_{ij} 进行建模。

$$\begin{aligned} p(\mathbf{c}_{ij}|a_{ij}, \mathbf{U}, \mathbf{M}, \mathbf{z}_{ij}) &= \prod_{k=1}^K N(\mathbf{d}_{ij} - a_{ij}\mathbf{d}_{ij} | \mathbf{u}_k, \mathbf{M}_{k::}^{-1})^{z_{ijk}} \\ p(\mathbf{z}_{ij}|\pi) &= \prod_{k=1}^K \pi_k^{z_{ijk}} \end{aligned} \quad (\text{A-7})$$

其中 \mathbf{z}_{ij} 是与 c_{ij} 相关的指示向量，满足 $z_{ijk} \in \{0, 1\}$, $\sum_{k=1}^K z_{ijk} = 1$ 。 $\pi = (\pi_1, \dots, \pi_K)$ 是混合高斯分布的权重系数向量，其中 π_k 代表第 k 个高斯成分的存在概率， π 满足 $0 \leq \pi_k \leq 1$, $\sum_{k=1}^K \pi_k = 1$ 。 $\mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_K] \in \mathbb{R}^{2d \times K}$, $\mathbf{M} \in \mathbb{R}^{K \times 2d \times 2d}$ 的第 k 个水平切片为 $\mathbf{M}_{k::}$; $\mathbf{u}_k, \mathbf{M}_{k::}$ 为第 k 个高斯成分的均值与协方差矩阵。再次为了便于下面的描述，我们让 $\mathbf{Z} \in \mathbb{R}^{m \times n \times K}$ 表示张量，其中第 (i, j, k) 个元素用 z_{ijk} 来表示。

参数 \mathbf{u}_k 和 $\mathbf{M}_{k::}$ 由高斯-维夏特分布建模如式A-8所示，其中 \mathbf{u}_{0k} 为均值向量 $\mathbf{M}_{0k::}$ 为协方差矩阵， ϕ_{0k} 为自由度。 β_2 是超参数。这里我们定义 $\mathbf{U}_0 = [\mathbf{u}_{01}, \dots, \mathbf{u}_{0K}] \in \mathbb{R}^{2d \times K}$, $\phi_0 = [\phi_{01}, \dots, \phi_{0K}] \in \mathbb{R}^K$, $\mathbf{M}_0 \in \mathbb{R}^{K \times 2d \times 2d}$ 为张量切片为 $\mathbf{M}_{0k::}$:

$$p(\mathbf{u}_k, \mathbf{M}_{k::}) = N(\mathbf{u}_k | \mathbf{u}_{0k}, \beta_2^{-1} \mathbf{M}_{k::}^{-1}) \cdot W(\mathbf{M}_{k::} | \mathbf{M}_{0k::}, \phi_{0k}) \quad (\text{A-8})$$

混合系数 π 由 Dirichlet 分布建模，如式A-9所示，其中 $\Gamma(\cdot)$ 为 gamma 函数， $\{\eta_{0k}\}$ 为超参数。

$$p(\pi) = \frac{\Gamma(\hat{\eta}_0)}{\Gamma(\eta_0) \cdots \Gamma(\eta_K)} \prod_{k=1}^K \pi_k^{\eta_{0k}-1}, \hat{\eta}_0 = \sum_{k=1}^K \eta_{0k} \quad (\text{A-9})$$

基于上述假设，潜变量 $\mathbf{A}, \mathbf{E}, \mathbf{U}, \mathbf{M}, \mathbf{Z}, \pi$ 与极化 SAR 图像数据 \mathbf{D} 的联合分布表示为：

$$\begin{aligned} p(\mathbf{D}, \mathbf{A}, \mathbf{E}, \mathbf{U}, \mathbf{M}, \mathbf{Z}, \pi) &= \prod_{i,j,k} p(\mathbf{d}_{ij} | a_{ij}, e_{ij}, \mathbf{u}_k, \mathbf{M}_{k::}, z_{ijk}, \pi_k) \cdot p(a_{ij} | e_{ij}) \cdot p(e_{ij}) \\ &\quad \cdot p(\mathbf{u}_k, \mathbf{M}_{k::}) \cdot p(z_{ijk} | \pi_k) \cdot p(\pi_k) \end{aligned} \quad (\text{A-10})$$

A.3 变分贝叶斯推断

我们将用于单通道 SAR 图像的变分贝叶斯推断原理应用于极化 SAR 图像舰船检测。与原始概率模型的变分贝叶斯推断先比，由于在第二节中建立了精准的概率模型，简化了变分贝叶斯推断的过程。

A.3.1 变分贝叶斯推断原理

变分贝叶斯推断是一种低计算复杂度的近似方法，可以通过适当的初始化得到所期望的最终结果。变分贝叶斯推断通过最小化 Kullback-Leibler(KL) 散度来计算真实后验分布 $p(\mathbf{X}|\mathbf{Y})$ 的近似分布 $q(\mathbf{Y})$ 。

$$\text{KL}(q|p) = - \int q(\mathbf{Y}) \ln\left(\frac{p(\mathbf{Y}|\mathbf{X})}{q(\mathbf{Y})}\right) \quad (\text{A-11})$$

其中 \mathbf{Y} 与 \mathbf{X} 分别为潜变量与观测的数据变量。实际上可以通过最小化不同的散度函数得到不同的近似值。通过最小化 KL 散度获得的 $q(\mathbf{Y})$ 在高概率的变量空间区域中有很大的概率权重。但是我们反向最小化 KL 散度，则获得的近似值 $q(\mathbf{Y})$ 在低概率变量空间区域中有很高的概率权重。在这里我们使用 KL 散度，这也是很多文献中的常见做法，我们进一步假设 \mathbf{Y} 可以划分为 L 个不相关的组。

$$q(\mathbf{Y}) = \prod_{l=1}^L q(\mathbf{Y}_l) \quad (\text{A-12})$$

那么 $q(\mathbf{Y}_l)$ 可以通过交替的方式获得

$$\ln q(\mathbf{Y}_l) = E_{g \neq l}(\ln(p(\mathbf{Y}, \mathbf{X}))) + \text{const} \quad (\text{A-13})$$

其中 $E_{g \neq l}(\cdot)$ 定义了与 q 分布中所有满足 $g \neq l$ 的变量 \mathbf{Y}_g 的期望。通过归一化分布 $q(\mathbf{Y}_l)$ 来设置式A-13中的加性常数。我们对该式取指数然后归一化得到

$$q^*(\mathbf{Y}_l) = \frac{\exp(E_{g \neq l}[\ln(p(\mathbf{Y}, \mathbf{X}))])}{\int \exp(E_{g \neq l}[\ln(p(\mathbf{Y}, \mathbf{X}))]) d\mathbf{Y}_l} \quad (\text{A-14})$$

A.3.2 变分贝叶斯推断在舰船检测中的应用

对于先前建立的概率模型，我们有 $Y = \{\mathbf{A}, \mathbf{E}, \mathbf{U}, \mathbf{M}, \mathbf{Z}, \pi\}$ 和 $\mathbf{X} = \mathbf{D}$ 。同时相应的后验分布估计是独立的。

$$\begin{aligned} q(\mathbf{Y}) &= q(\mathbf{A}) \cdot q(\mathbf{E}) \cdot q(\mathbf{U}, \mathbf{M}) \cdot q(\mathbf{Z}) \cdot q(\pi) \\ &= \prod_{i,j,k} q(a_{ij})q(e_{ij})q(\mathbf{u}_k, \mathbf{M}_{k:,:})q(z_{ijk})q(\pi_k) \end{aligned} \quad (\text{A-15})$$

然后将式A-10带入到式A-13中计算式A-15中的参数。在此潜变量的后验分布近似值列出如下，具体的变分贝叶斯推断过程与一些有用的中间变量的期望在附录 A 与附录 B 中详细介绍。

1) \mathbf{A} 与 \mathbf{E} 的期望， \mathbf{A} 中每个 a_{ij} 的后验分布近似为

$$q(a_{ij}) = N(a_{ij} | E(a_{ij}), \Sigma_{a_{ij}}^{-1}) \quad (\text{A-16})$$

其中参数如式A-17所示， $\psi(\cdot)$ 为 digamma 函数。

$$\begin{aligned} \Sigma_{a_{ij}} &= \sum_k E(z_{ijk}) \mathbf{d}_{ij:}^T E(\mathbf{M}_{k:,:}) \mathbf{d}_{ij:} \\ E(a_{ij}) &= \sum_{a_{ij}}^{-1} \left(\sum_k E(z_{ijk}) \mathbf{d}_{ij:}^T E(\mathbf{M}_{k:,:}) (\mathbf{d}_{ij:} - E(\mathbf{u}_k)) \right) + \sum_{a_{ij}}^{-1} (\psi(\alpha_0) - \psi(\beta_0)) \end{aligned} \quad (\text{A-17})$$

\mathbf{E} 中的后验分布 e_{ij} 可以近似为

$$q(e_{ij}) = \text{Beta}(e_{ij} | \alpha_0^*, \beta_0^*) \quad (\text{A-18})$$

参数为

$$\alpha_0^* = E(a_{ij}) + \alpha_0, \beta_0^* = \beta_0 - E(a_{ij}) + 1 \quad (\text{A-19})$$

2) 估计 \mathbf{U} 和 \mathbf{M} : \mathbf{u}_k 和 $\mathbf{M}_{k:,:}$ 的后验分布估计为

$$q(u_k, \mathbf{M}_{k:,:}) = N(u_k | E(u_k), \sum_{u_k}^{-1}) \cdot W(\mathbf{M}_{k:,:} | E(\mathbf{M}_{k:,:} | \phi_k^{-1}, \phi_k)) \quad (\text{A-20})$$

其中参数为

$$\begin{aligned}
\beta_k &= \sum_{i,j} E(z_{ijk}) + \beta_2 \\
E(u_k) &= \frac{1}{\beta_k} \left(\sum_{i,j} E(z_{ijk})(d_{ij:} - E(a_{ij})d_{ij:}) - \beta_2 u_{0k} \right) \\
\Sigma_{u_k} &= \beta_k E(M_{k:,:}) \\
\phi_k &= \sum_{i,j} E(z_{ijk}) + \phi_{0k} + 1
\end{aligned} \tag{A-21}$$

3) 估计 \mathbf{Z} 和 π , \mathbf{Z} 中的每个元素 z_{ij} 的后验分布近似为:

$$q(\mathbf{z}_{ij}) = \prod_{k=1}^K \rho_{ijk}^{z_{ijk}} \tag{A-22}$$

参数为

$$\begin{aligned}
\rho_{ijk} &= \frac{\xi_{ijk}}{\sum_k \xi_{ijk}} \\
\ln \xi_{ijk} &= \frac{1}{2} E(\ln |\mathbf{M}_{k:,:}|) - 3 \ln 2\pi \\
&+ E(\ln \pi_k) - \frac{1}{2} E((d_{ij:} - a_{ij} d_{ij:} - u_k)^T M_{k:,:} (d_{ij:} - a_{ij} d_{ij:} - u_k)) + const
\end{aligned} \tag{A-23}$$

π 的后验概率分布为:

$$q(\pi) = \prod_{k=1}^K \pi_k^{\eta_{1k}-1} \tag{A-24}$$

参数为

$$\eta_{1k} = \sum_{i,j} E(z_{ijk}) + \eta_{0k} \tag{A-25}$$

A.3.3 算法

我们的目的是估计 \mathbf{A} 的期望。实际上式A-16清晰的表明了 $q(\mathbf{A})$ 的期望估计依赖于其他参数的期望。因此在迭代变分贝叶斯推断过程中, 我们首先对所有参数做适当初始化, 然后根据式A-16-式A-24更新这些参数的估计结果, 知道达到收敛。算法6总结了我们提出的舰船检测算法完整过程。

当迭代次数达到预定义值或者连续两次 $\mathbf{A} * \mathbf{D}$ 的估计值的相对变化小于给

Algorithm 6: 基于变分贝叶斯推断的舰船检测方法

Input: 极化 SAR 图像 \mathbf{D}

- 1 初始化:
 - 2 初始化潜变量 $\mathbf{Y}^0 = \{\mathbf{A}^0, \mathbf{U}^0, \mathbf{M}^0, \mathbf{Z}^0, \pi^0\}$
 - 3 初始化超参数 $\alpha_0, \beta_0, \beta_1, \beta_2, \{\eta_{0k}\}$
 - 4 选个混个多元高斯分布的个数 K , 设置迭代停止条件 $thres$ 或 M , $t=0$.
 - 5 **while** $thr > thres$ **do**
 - 6 $t=t+1$
 - 7 通过 \mathbf{Y}^{t-1} 与式A-16估计 \mathbf{A} 与 \mathbf{E} 的后验分布, 更新 \mathbf{A}^t 与 \mathbf{E}^t .
 - 8 通过 \mathbf{Y}^{t-1} 与式A-20估计 \mathbf{U} 与 \mathbf{M} 的后验分布, 更新 \mathbf{U}^t 与 \mathbf{M}^t .
 - 9 通过 \mathbf{Y}^{t-1} 与式A-22估计 \mathbf{Z} 与 π 的后验分布, 更新 \mathbf{Z}^t 与 π^t .
 - 10 更新阈值 $thr = \frac{\|E(\mathbf{A}^t * \mathbf{D}^t) - E(\mathbf{A}^{t-1} * \mathbf{D}^{t-1})\|_F}{\|E(\mathbf{A}^{t-1} * \mathbf{D}^{t-1})\|_F}$
 - 11 **end**
 - 12 通过式??计算 $\hat{\mathbf{A}}$ **Output:** 最终舰船检测结果 $\hat{\mathbf{A}}$
-

定常数时, 上述迭代过程停止。

$$\frac{\|E(\mathbf{A}^t * \mathbf{D}^t) - E(\mathbf{A}^{t-1} * \mathbf{D}^{t-1})\|_F}{\|E(\mathbf{A}^{t-1} * \mathbf{D}^{t-1})\|_F} < thres \quad (\text{A-26})$$

其中 t 代表了第 t 次迭代, $\|\cdot\|_F$ 代表 Frobenius 范数, $thres$ 是收敛阈值被设置为很小的常数。当迭代过程收敛我们令

$$\hat{a}_{ij} = \begin{cases} 1 & e_{ij}^t \geq 0.5 \\ 0 & e_{ij}^t < 0.5 \end{cases} \quad (\text{A-27})$$

最终二值矩阵 $\hat{\mathbf{A}} = [\hat{a}_{ij}]$ 被作为最终的检测结果。

A.4 实验与结果

实验使用在新加坡海峡与大连港区域采集的 C 波段 RADASAT-2 极化 SAR 图像, 图像参数如表A-1所示。泡利矢量彩色编码图像如图A-1所示, 这里考虑了互易性与泡利基。在下文中我们首先描述所提方法的参数设置, 然后定义了图像的真实值。最后采用最新的极化 SAR 舰船检测方法 GP-PNF 检测器与全局

排序检测器迭代检测方法作为参考方法证明了该方法的有效性。

表 A-1 极化 SAR 图像参数

位置	日期	区域 (pix-els)	分辨率 (m)	像素空间	入射角。
新加坡海峡	19/01/2013	2070×1227	5.2×7.6	4.7×4.8	47
大连港	17/04/2012	1734×871	5.2×7.6	4.7×5.3	21

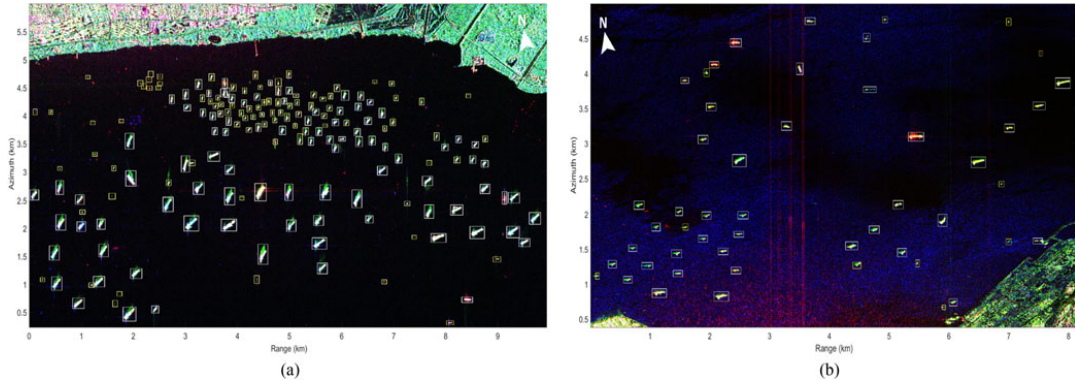


图 A-1 RADARSAT-2 极化 SAR 图像 (a) 新加坡海峡 (b) 大连港

A.4.1 参数设置

由于变分贝叶斯推断有可能会找到局部最优解，因此必须对算法6进行适当的初始化。在下文中，我们详细介绍了该方法潜变量的初始化和超参数设置。

1) 初始化潜变量：我们采用一种简单的方法来初始化潜变量。首先我们对 \mathbf{D} 中所有的像素的 SPAN 值做升序排序。然后我们将前 85% 有较低 SPAN 值的像素作为海杂波像素，其他有更高 SPAN 值的像素作为舰船像素。因此我们获得了粗略的检测结果，其被用于初始化 \mathbf{A}_0 。

粗略检测得到的杂波像素值用于估计混合高斯分布的参数，其被用来初始化与海杂波 \mathbf{C} 相关的潜变量。我们使用贝叶斯信息准则选择混合高斯分布的分量数 K 。在我们实验中，我们发现五分量的混合多元高斯分布具有足够的灵活性以适合海杂波的分布。每个 $\mathbf{u}_k^0, M_{k::}^0, \pi_k^0$ 都使用粗略检测的杂波像素来初始化。每个 z_{ij}^0 被初始化为随机的 K 维指示向量。每个 ϕ_k 设置为不小于 $2d-1$ 的数字，这里我们设置 ϕ_k 为 6。

对于迭代停止条件，我们发现两次连续的 $\mathbf{A} * \mathbf{D}$ 估计值之间的相对变化在五次迭代后总是小于 10^{-4} 。因此我们设置 $thres = 10^{-4}$ ，或简单的设置最大迭代次

数 $M=10$ 。在以下实验中我们采用后者。

2) 超参数设置：以非信息的方式设置算法6中的所有超参数，以减少他们对后验分布估计的影响。因此 $\beta_1, \beta_2, \eta_{0k}$ 均被设置为 10^{-6} 。对于稀疏相关的超参数 α_0 设置为 10^{-3} ，并设置 $\beta_0 = 1 - \alpha_0$ 。

A.4.2 定义真值

A.4.3 检测结果

A.5 结论